Сергей Ермолаев

saermolaev.w@gmail.com +7 (930) 802-31-25 Нижний Новгород ENG CV.

Обо мне

AI / Machine Learning Engineer с 3 годами коммерческого опыта. Работал с классификацией, компьютерным зрением и обработкой речи. Сейчас основной фокус — **RAG, LLM-инференс, AI-агенты и гибридный поиск**. Сильная сторона — быстрое прототипирование ML/AI-решений, от проверки гипотез до готового демо. Довожу решения до production с оценкой качества и мониторингом, оптимизирую их под требования к скорости и вычислительным ресурсам.

Опыт

Протон *(IT-компания ГК* ***"АГАТ"****, топ-5 автодилеров РФ, 120+ автосалонов)* Нижний Новгород
ML Engineer: Нояб. 2023 – Н. в.

- **Многометочная классификация звонков**: F1-samples **79% → 94%**, EMR **3% → 61.6%**; инференс на CPU за доли секунды, **>1000 звонков ежедневно**. Подготовка данных, транскрибация, стратификация, эксперименты и интеграция в production. По оценке аналитиков компании, экономический эффект **~170 млн ₽**.
- **RAG-ассистент (RAGFlow + vLLM)**: user satisfaction **4.7/5**, faithfulness **95%**, **TTFT p99 4.6s** под нагрузкой с большим контекстом. Подбор моделей, доработка RAGFlow под корпоративную БЗ, собственный пайплайн исправления и парсинга документов. Развёртывание в production, мониторинг, трейсинг и оценка качества.
- **Агент** маршрутизации тикетов в системе управления бизнесом GANDIVA с использованием RAG, Guardrails, Memory. Полный цикл разработки, включая мониторинг и оценку качества / производительности *(LangGraph, RAGFlow, LangFuse, vLLM)*.
- **Система подбора автозапчастей**: снижение обращений к подборщикам с **300 до 20 в день (−93%)**. Реализация гибридного поиска с собственной функцией ранжирования и порогами отбора, создание словаря сокращений. Развёртывание сервиса на **FastAPI + Docker** в production.
- **LLM-разметка** звонков (Mistral/Qwen, zero-/few-shot, **LoRA Qwen2.5-3B**): Accuracy до 90% (LoRA), прод — XLinear 88% (CPU онлайн/офлайн).
- **CV-трекинг** тест-драйвов: YOLOv5, мультипоточность, кропы; точность 65%→87%, до 15 fps на Consumer GPU.

Проекты

НИУ ВШЭ НН *(Академический R&D)* Сент. 2022 – Май 2023
ML Engineer | *WhisperX, Llama.cpp, aiogram, guidance. GitHub*

- Разработка автономного AI-ассистента (Telegram Bot на aiogram) для транскрибации и суммаризации аудио с фокусом на Data Privacy. Спроектировал ASR-пайплайн на базе WhisperX с выравниванием текста и regex-фильтрацией шума. Реализовал гибридный (CPU/GPU) инференс квантованной LLM через llama.cpp с кастомным управлением памятью и жестким контролем генерации через фреймворк guidance. Проект полностью независим от внешних API и оптимизирован для локального запуска на потребительском железе (от 12GB VRAM).

НИУ ВШЭ НН *(совместный R&D проект с бизнесом)* Февр. 2021 – Май 2021
ML Researcher | *Selenium, Colabeler, torchvision*

- Проектирование пайплайна сбора и подготовки данных для CV-модели детекции повреждений автомобилей. Сбор датасета, разметка, аугментация, баланс классов.

Образование

Национальный исследовательский университет «Высшая школа экономики» Нижний Новгород, Россия
Магистратура, Интеллектуальный анализ данных *Сент. 2022 – Июнь 2024*

Национальный исследовательский университет «Высшая школа экономики» Нижний Новгород, Россия
Бакалавриат, Прикладная математика и информатика *Сент. 2018 – Июнь 2022*

Дополнительно

AI Agents Security Week *27.07.2026 – 31.07.2026*
Agents Week Школы анализа данных (YSDA) *06.04.2026 – 10.04.2026*
Интенсив ШАД Яндекс: LLM Scaling Week *10.11.2025 – 14.11.2025*

Навыки

DL/ML: Python, PyTorch, vLLM, transformers, LangChain, LangGraph, llama.cpp, deepeval, RAGFlow, NumPy, prompt engineering, infinity, unsloth, scikit-learn, WhisperX, spaCy.
Infra/Tools: Linux, Docker, FastAPI, Git, DVC, streamlit, LangFuse, W&B, matplotlib, Grafana, Kubeflow
Data: pandas, polars, SQL
Languages: Russian - Native, English - B2 / Upper-Intermediate