

Сергей Ермолаев

✉ @J1nsei ✉ saermolaev.w@gmail.com ☎ +7 (930) 802-31-25 📍 Нижний Новгород 🇺🇸 ENG CV.

Обо мне

AI / Machine Learning Engineer с 3+ годами опыта в ML, включая **2.5 года** end-to-end разработки production ML-систем. Основной фокус: **RAG, LLM-инференс, ИИ-агенты**, мультилейбл-классификация и гибридный поиск. Сильные стороны: интеграция LLM в production под жёсткие требования к latency и ресурсам, проектирование ML/AI-пайплайнов от прототипа до деплоя, мониторинга и оценки качества. Образование: **ВШЭ**, ПМИ + ИАД.

Опыт

Протон (IT-компания ГК "АГАТ", *топ-5 автодилеров РФ* [↗](#), 120+ автосалонов)

Нижний Новгород

ML Engineer:

Нояб. 2023 – Н. в.

- Multilabel-классификация звонков: **F1-samples 79% → 94%, EMR 3% → 61.6%**; CPU инференс за доли секунды, >1000 звонков ежедневно; экономический эффект **~170 млн ₽**. Сбор и обработка данных: транскрибация, очистка, анализ, стратификация в условиях многометочности; проведение экспериментов, интеграция в прод.
- **RAG**-ассистент (RAGFlow + vLLM): **user satisfaction 4.7/5, TTFT p99 4.6s** под нагрузкой с большим контекстом, **faithfulness 95%**. Доработка функционала библиотеки под особенности корпоративной БЗ, выбор стеков/моделей, кастомный пайплайн исправления и парсинга документов, Docker, разворачивание проекта на прод-сервер с мониторингом и трейсингом, измерение производительности и качества, подготовка документации по использованию и поддержке.
- **Агент** маршрутизации тикетов в системе управления бизнесом GANDIVA с использованием RAG, Guardrails, Memory. Полный цикл разработки, включая мониторинг и оценку качества / производительности (*LangGraph, RAGFlow, LangFuse, vLLM*).
- Система подбора автозапчастей: снижение обращений **300→20/день** (-93%). Подбор БД по встроенным возможностям и скорости работы. Реализация **гибридного поиска**, кастомная функция ранжирования и пороги, оборачивание в FastAPI + Docker; создание словаря сокращений (regex + LLM + ручная вёрстка) и документации, интеграция с прод-сервером.
- **LLM-разметка** звонков (Mistral/Qwen, zero-/few-shot, **LoRA Qwen2.5-3B**): Accuracy до 90% (LoRA), прод — XLinear 88% (CPU онлайн/офлайн).
- **CV-трекинг** тест-драйвов: YOLOv5, мультипоточность, кропы; точность 65%→87%, до 15 fps на Consumer GPU.

Проекты

НИУ ВШЭ НН (Академический R&D)

Сент. 2022 – Май

ML Engineer | *WhisperX, Llama.cpp, aiogram, guidance*. [GitHub](#) [↗](#)

2023

- Разработка автономного AI-ассистента (Telegram Bot на aiogram) для транскрибации и суммаризации аудио с фокусом на Data Privacy. Спроектировал ASR-пайплайн на базе WhisperX с выравниванием текста и regex-фильтрацией шума. Реализовал гибридный (CPU/GPU) инференс квантованной LLM через llama.cpp с кастомным управлением памятью и жестким контролем генерации через фреймворк guidance. Проект полностью независим от внешних API и оптимизирован для локального запуска на потребительском железе (от 12GB VRAM).

НИУ ВШЭ НН (совместный R&D проект с бизнесом)

Февр. 2021 – Май

ML Researcher | *Selenium, Colabeler, torchvision*

2021

- Проектирование пайплайна сбора и подготовки данных для CV-модели детекции повреждений автомобилей. Сбор датасета, разметка, аугментация, баланс классов.

Образование

Национальный исследовательский университет «Высшая школа экономики» <i>Магистратура, Интеллектуальный анализ данных</i>	Нижний Новгород, Россия Сент. 2022 – Июнь 2024
Национальный исследовательский университет «Высшая школа экономики» <i>Бакалавриат, Прикладная математика и информатика</i>	Нижний Новгород, Россия Сент. 2018 – Июнь 2022
Дополнительно	
Интенсив ШАД Яндекс: LLM Scaling Week 	10.11.2025 – 14.11.2025
Agents Week Школы анализа данных (YSDA) 	06.04.2026 – 10.04.2026

Навыки

DL/ML: Python, PyTorch, vLLM, transformers, LangChain, LangGraph, llama.cpp, deepeval, RAGFlow, NumPy, prompt engineering, infinity, unsloth, scikit-learn, WhisperX, spaCy.

Infra/Tools: Linux, Docker, FastAPI, Git, DVC, streamlit, LangFuse, W&B, matplotlib, Grafana, Kubeflow

Data: pandas, polars, SQL

Languages: Russian - Native, English - B2 / Upper-Intermediate